

二、研究計畫內容：

1. 摘要

龍舟運動是一項結合團隊協作與高強度爆發力的競技項目，划槳技術的一致性與發力結構對比賽成績具有關鍵影響。然而，目前台灣龍舟訓練仍多依賴教練主觀觀察，缺乏即時、量化且可重複驗證的科學分析工具。雖然部分運動科學應用穿戴式感測器（如加速度計與陀螺儀）進行分析，但此類設備成本較高且資料解讀門檻高，難以在一般訓練環境中普及。因此，本專案將結合電腦視覺與深度學習技術，開發一套非侵入式之龍舟動作分析系統，以影像為基礎解析選手於室內划船機上的運動生物力學特徵。

本專案將開發一套供教練與選手使用的自動化動作分析工具使用者透過上傳側拍訓練影片，自動完成影像前處理與深度模型推論，從影像中擷取划槳軌跡與關節角度等關鍵資訊，轉換為可視化疊圖與量化運動參數（如入水角度、回槳時間與關鍵關節角度等）。此方法不需配戴任何感測裝置，能降低使用門檻並提升分析效率，同時建立標準化動作資料，以利長期技術追蹤與修正。


技術架構方面，本專案採用 YOLOv11 [1] 來進行船槳的物件偵測，並結合 ViTPose [2] 與 TCPFormer (Temporal Correlation with Implicit Pose Proxy)[3] 模型進行 2D 轉 3D 的人體姿態估計 (Pose Estimation)，從影像中萃取肩、肘、腕與脊椎等關鍵關節之空間特徵。最後整合時序分析方法，計算划槳過程中的角速度與節奏一致性等動態指標，解決傳統影像分析僅能追蹤軌跡卻無法量化發力結構的問題，達到科學化訓練輔助的效果。

2. 研究動機與研究問題

近些年來，隨著人工智慧與電腦視覺技術的飛速發展，透過影像進行人體姿態估計 (Pose Estimation) 與動作分析已相當成熟。然而，目前的運動科技研究多集中於主流球類運動；在龍舟 (Dragon Boat) 這項結合團隊協作與高強度爆發力的競技項目中，相關研究相對匱乏。現有的龍舟技術分析往往面臨兩大挑戰：一是水上環

境變因過多（如船身晃動、水花飛濺），難以精確捕捉動作細節；二是缺乏有效的量化工具，導致訓練成效高度依賴教練的主觀感覺。

鑑於上述挑戰，室內龍舟划船機（圖一）作為選手建立肌肉記憶與修正動作基礎的關鍵場域，成為了導入影像分析的最佳切入點。在室內環境中，能排除外界環境干擾，針對選手的「發力結構」與「姿勢標準度」進行更純粹的生物力學分析。然而，目前市面上針對龍舟划船機的分析，仍多僅限於面板上的功率與轉速數據，缺乏針對「人體動作軌跡」的視覺化分析系統。



圖一、不同背景的划船機對照圖

因此，本專案動機源於解決龍舟隊實際訓練需求。我們將利用電腦視覺技術，專注於分析室內划船機的訓練影像。透過演算法精準捕捉選手在穩定環境下的關鍵關節點，計算划槳角度、身體前傾幅度與回槳節奏等進階指標。這不僅能協助教練在非水上訓練期間進行精細的動作雕琢，更能建立一套標準化的動作數據庫，發掘傳統人力分析難以察覺的關鍵致勝因素。

但在走向實務的過程中，面臨了以下幾個必須克服的技術挑戰：首先是資料前處理與標註的標準化。實際拍攝的訓練影片不像實驗室環境那樣單純，往往伴隨著光線變化、背景雜亂或解析度不一等狀況。因此，如何將這些原始影片處理為品質穩定的逐幀影像，並建立一套一致的標註標準，是確保後續模型品質的首要基礎。

再來是模型在複雜環境下的穩定性。在非受控的訓練場域中，選手的肢體遮擋、劇烈的姿態變化或與鏡頭的距離差異，都可能導致辨識失準。因此需要評估並調整模型架構，確保它在面對這些現實干擾時，依然能穩定且準確地抓取人體骨架與船隻位置。

最後則是多模型結果的整合應用。由於本專案分別運用不同模型來偵測人體與船隻器材，兩者輸出的資料格式與時間基準可能存在差異。如何有效地對齊並整合這些數據，將其轉化為具備時序關聯性的動作分析，將是本專案最終能否產出有效回饋的關鍵。

總結來說，雖然傳統感測器與單純物件偵測已奠定部分基礎，但皆無法同時滿足「非侵入性」與「精確人體生物力學分析」之需求。因此，本專案將整合 YOLOv11 的高精度器材偵測能力，並採用 ViTPose 結合 TCPFormer 的先進架構，構建一套能同時捕捉器材軌跡與人體 3D 發力結構的綜合分析系統，且具備低成本與高便攜性的優勢，大幅降低運動力學分析的門檻，此系統填補了現有研究之缺口。

3. 文獻回顧和探討

3.1 傳統感測器技術於划船運動之應用與限制

在龍舟與獨木舟等划槳運動的技術分析中，穿戴式裝置與慣性測量單(IMU) 長期以來扮演著關鍵角色。Liu 等人提出利用多感測器融合技術[4]來追蹤划船動作，透過在船槳與選手身上安裝傳感器，成功量化了划槳頻率與力量分佈。最新的研究如 Parab 等人亦利用智慧型裝置 (Smart Devices) 進行划船品質評估，證實了機器學習模型可依據慣性訊號區分動作優劣[5]。

然而，此類技術在實務應用上仍面臨顯著挑戰。首先是「侵入性」問題，多感測器的配置（如同時佩戴手錶、臂套）易對選手的高強度動作造成干擾，降低了訓練的生態效度。其次是數據的「抽象性」，感測器僅能回傳加速度波形或數值，無法直觀還原選手的肢體幾何姿態，導致教練難以針對具體的關節角度（如脊椎前傾、手肘高度）進行修正。因此，發展非接觸式的影像分析技術成為必然趨勢。

3.2 運動偵測之深度學習技術

隨著卷積神經網路 (CNN) 的發展，物件偵測 (Object Detection) 技術已被廣泛應用於運動器材的追蹤。從早期的 Faster R-CNN[6] 到近期的 YOLO 系列，偵測速度與精度均有顯著提升。針對划槳運動，Najlaoui 等人於 2024 年提出了一套

AI 驅動的划槳動作偵測系統[7]，利用 YOLO 模型精確捕捉水上划船的船槳軌跡，證明了電腦視覺在排除穿戴式裝置干擾下，仍能有效監控器材動態。

本專案擬採用最新的 YOLOv11 模型，相較於前代版本，其在特徵提取與小物件偵測上具有更佳效能，能更精確地定位高速移動中的船槳與室內划船機結構。然而，單純追蹤「器材」僅能反映運動結果，無法解釋造成該運動的「人體發力機制」，因此必須結合人體姿態估計技術。

3.3 人體姿態估計技術：從 2D 到 3D 的時序建模

人體姿態估計（Human Pose Estimation）是解析運動員生物力學特徵的核心技術。Xu 等人提出的 ViTPose 利用 Vision Transformer 架構，在 2D 關鍵點檢測上展現了極高的穩健性，能有效處理複雜背景下的姿態辨識。然而，單純的 2D 資訊缺乏深度維度，難以精確計算關節的旋轉角度與空間位移。

為了從單目影像中重建 3D 姿態，學界陸續提出了多種時序建模方法。MotionBERT [8] 與 MHFormer [4] 強調了從 2D 到 3D 的特徵映射能力；MixSTE [9] 則透過混合時空編碼器來捕捉長序列的動作特徵。針對動作的時序連貫性，Liu 等人於 2025 年發表的 TCPFormer，提出了一種基於隱式姿態代理的時序關聯學習機制，能有效解決前後幀動作抖動與遮擋問題，大幅提升了 3D 重建的穩定性。

4. 研究方法及步驟

4.1 系統開發環境

表一、系統開發環境


系統開發環境	
硬體	處理器：Intel(R) Core(TM) i7-9700K CPU @ 3.60GHz 記憶體： 31 GB 顯示卡：GeForce RTX 3090
環境	conda 25.11.1
作業系統	Ubuntu 22.04.3 LTS

4.2 系統流程設計

本專案系統之整體流程設計如下：首先，使用者登入分析網站並上傳拍攝之龍舟訓練影片後，系統將先進行影片格式與基本完整性檢查；若影片格式不符合系統規範，則自動終止流程並刪除上傳檔案，以確保後續分析之穩定性。當影片格式確認正確後，系統即進入分析階段。

在分析過程中，系統將同步啟動人體骨架偵測模型 TCPformer 3D 與船槳偵測模型 YOLO v11。其中，YOLO v11 負責於每一影格中偵測船槳位置，並由連續影格之偵測結果建構船槳之即時二維（2D）運動軌跡，進而萃取對應之 2D 時序數據，包含槳端位移、速度與加速度等運動特徵。同時，TCPformer 3D 模型則從影片中重建運動員之三維（3D）人體骨架結構，取得各主要關節於 3D 空間中包含肩關節、肘關節等關鍵關節之角度變化資訊。


最後，系統將上述分析結果彙整，以視覺化方式呈現於前端介面中，同時提供對應之量化數據與動作分析指標，作為使用者進行訓練評估與技術調整之參考，完成整體分析流程。



圖二、龍舟划槳辨識系統流程圖

4.3 系統架構

當使用者將影片上傳後，系統會並行處理不同任務。第一部分，後端模型首先使用物件偵測模組 YOLO v11 定位划槳的位置，獲得槳的中心座標序列後繪製出連續的划槳軌跡，並計算相關數據（入水度、划槳頻率等）。第二部分，首先運用預訓練的 Faster R-CNN 作為目標偵測器，把目標框出。接著，使用 VITPose 模型提取全身的 2D 關節點。隨後將標出的數據傳到 TCPFormer 進行 2D 關節點轉 3D 座標，輸出座標矩陣然後透過套件（Matplotlib 或 Open3D）進行視覺化。




圖三、龍舟划槳辨識系統架構圖

4.3.1 划槳偵測 (Paddle Detection)

划槳屬於細長且高速移動之目標物件，於實際訓練場景中常伴隨運動模糊、背景雜訊與視角變化，因此對模型在低延遲條件下維持高特徵解析力具有較高要求。

為實現即時且穩定的划槳偵測能力，在論文[1]中提到YOLOv11是目前性能最強的模型，YOLOv11s 在維持高精確度的同時，也能夠保持低延遲運行。因此本專案選定 YOLOv11 作為核心模型，並採用知識蒸餾 (Knowledge Distillation[11]) 策略(圖四)，先透過 Transformer 架構的 RF-DETR[12] 其全域感受野 (Global Receptive Field) 對複雜背景的強大解析能力來生成高可信度的偽標籤 (Pseudo-labels)。這使得輕量級的 YOLOv11 模型能夠有效的訓練，解決了傳統 CNN 模型在缺乏大規模人工標註數據下難以冷啟動的問題，為後續的即時分析奠定基礎。



圖四、YOLOv11訓練過程

4.3.2 Paddle Visualization

在划槳動作視覺化階段，因為船槳在高速運動旋轉會導致邊界框的短暫消失或偏移，為提升船槳方向估測之穩定性，本專案利用船槳與背景在影像亮度上的差異，於邊界框內選取最可能對應船槳實體之線段，作為船槳端點與方向判定依據。

在連續影像中，系統結合前一幀影像的位置與速度資訊進行慣性預測，並透過平滑化處理建構連續且平穩的船槳二維運動軌跡。最終系統可由船槳端點時間序列計算位移與速度等二維運動數據，並將運動軌跡以螢光線疊加顯示於原始影片上。

4.3.3 人體偵測 (Human Detection)

在龍舟訓練影片中，受試者往往處於多人密集的场景，且划槳過程中容易因肢

體交錯、姿態變化或短暫遮擋而造成偵測困難，為了確保系統具備極高的召回率 (Recall) 並防止漏抓，本專案選用了 Faster R-CNN 進行全圖目標偵測。該模型憑藉其 RPN (Region Proposal Network) [6] 架構，能有效應對上述挑戰。此外，針對影片中出現複數人物的情形，本專案透過中心點輔助判斷鎖定目標，將其有效框出後傳入 ViTPose 進行處理。實作上，使用現有的 Faster R-CNN 模型，沒有進行任何微調 (fine-tuned)。

4.3.4 人體關節點偵測(2D Body joint Detection)

在龍舟划槳動作中常見的嚴重肢體遮擋與動態模糊等問題造成人體關節點標註常常出現誤差，傳統 CNN 模型受限於局部感受野 (Local Receptive Field)，往往難以在特徵缺失的情況下精準定位。本專案選用 ViTPose 模型憑藉 Transformer 架構核心的 全域注意力機制 (Global Attention)，能有效捕捉長距離的空間特徵關聯；即使關鍵關節點被遮擋，模型仍能透過上下文資訊推斷其位置，這對於後續計算精確的划槳角度與肢體同步率至關重要。

採用自訓練 (Self-training) 與知識蒸餾的流程來克服小樣本數據的限制：首先利用在 COCO 數據集上預訓練的 ViTPose 作為「教師模型」，對龍舟影片進行推論以生成偽標籤 (Pseudo-labels)。接著，以 MAE (Masked Autoencoder)[13] 權重初始化的「學生模型」進行微調。過程中引入 逐層學習率衰減 (Layer-wise Learning Rate Decay) 機制：讓淺層網絡保留 MAE 的通用視覺特徵，而深層網絡則以較高學習率快速適應龍舟的特定動作。此策略不僅防止了模型在小規模數據集上的過擬合，更確保了收斂速度與預測效能。實作方面，本專案基 MMPose[14] 框架採用 Top-down 策略，能直接整合 Faster R-CNN 的人體偵測結果。模型最終將預測的熱點圖 (Heatmap) 透過座標轉化，轉換為帶有信心分數 (Confidence Score) 的標準 JSON 格式。

4.3.5 2D-to-3D Lifting

本專案旨在解決 2D 轉 3D 姿態估計過程中，因肢體遮擋或視角受限導致的時序不連續問題，以獲取高穩定度的人體運動軌跡。鑑於此需求，本專案選用 TCPFormer 作為核心模型，主因在於其獨創的「隱式姿態代理 (Implicit Pose Proxy)」

機制，能有效捕捉長時序的運動特徵。

論文[3]中的運作流程分為三步：首先，利用 PUM (Proxy Update Module) 透過 Cross-Attention 從未被遮擋的幀數中提取動作規律，並將關鍵特徵寫入 Proxy；接著，使用 PIM (Proxy Invocation Module)，依據前後文的時序邏輯推測被遮擋區域，將完整的動作規律融合進模糊或缺失的手臂位置；最後，透過 PAM (Proxy Attention Module) 將前兩個模組(PUM 與 PIM)建立的矩陣進行聚合 (Aggregation)，生成聚合注意力矩陣。此機制讓模型能同時掌握全域運動規律與局部幀間的關聯，進而輸出穩定且連續的 3D 人體骨架結果。


4.4 資料庫的來源與建立

本專案的資料來源是與東華大學體育中心合作並由其提供龍舟划槳訓練影像，其中共有 29 個 2 至 3 分鐘不同背景和人物衣著的訓練影片，我們將其依照每五秒一幀的方式拆分照片，其中一半使用手動標記的方式，將槳的位置標記出來，總照片數量為 5420 張。

5. 預期結果

本專案預期之操作介面設計以即時回饋、量化指標與視覺化輔助為核心理念，將深度學習模型的分析結果轉換為教練與運動員可直觀理解的運動參數。使用者僅需上傳訓練影片，系統即可自動完成船槳偵測、軌跡分析與動作參數計算，並同步呈現在影片畫面與右側之數值摘要區如圖五表示。

使用者透過操作介面上傳側視拍攝之龍舟訓練影片後，系統將自動進行船槳物件偵測，並將偵測到的槳框座標轉換為船槳端運動關鍵點，進而建立連續之船槳二維運動軌跡時間序列。同時，系統整合人體 2D 關節點偵測與 2D-to-3D 姿態重建模型，重建三維人體骨架結構於操作介面下方，以輔助動作分析。



圖五、操作介面

分析結果將以疊圖方式呈現在影片畫面中，包含船槳辨識框、槳端即時位置及其運動軌跡（實線），並同步顯示三維人體骨架與關節角度變化，讓使用者能直觀比對實際動作與模型分析結果。而右側之槳法參數摘要區彙整系統自影片中自動計算之關鍵動作指標，包含划槳時間、槳數、槳頻、以及三維的關節角度等參數。透過這些量化數據，使用者可快速掌握划槳節奏、動作幅度與穩定性，作為訓練評估與技術調整之依據。

6. 需要指導教授指導內容

在本專案中，研究內容主要運用電腦視覺與深度學習技術，包含物件偵測、人體姿態估計與時序模型分析，整體研究方向與指導教授於深度學習與影像分析相關研究領域相符。

自計畫初期階段起，我們即與教授深入討論龍舟動作分析之可行性與研究方向，並確認以 YOLO 系列模型進行船槳偵測，結合姿態估計與時序模型進行動作節奏與穩定性分析，為本專案之核心方法。教授於模型選擇與系統架構設計上提供重要建議，協助我們建立合理且可實作之分析流程。

隨著研究逐步深入，我們亦期待在教授的引導下，進一步探討更具挑戰性的議題，例如將模型實際應用於多人且於水面上的龍舟訓練並以此延伸後續研究方向。透過教授持續且系統性的指導，期望能穩健地完成一套具實用價值之龍舟動作分析系統，並為後續運動訓練與相關研究奠定良好基礎。

7. 參考文獻

- [1] R. Khanam and M. Hussain, "YOLOv11: An Overview of the Key Architectural Enhancements," arXiv.org, 2024.
- [2] Y. Xu, J. Zhang, Q. Zhang, and D. Tao, "ViTPose: Simple Vision Transformer Baselines for Human Pose Estimation," arXiv:2204.12484 [cs], May 2022, Available: <https://arxiv.org/abs/2204.12484>
- [3] J. Liu, M. Liu, H. Liu, and W. Li, "TCPFormer: Learning Temporal Correlation with Implicit Pose Proxy for 3D Human Pose Estimation," arXiv preprint arXiv:2501.01770, 2025.
- [4] W. Li, H. Liu, H. Tang, P. Wang, and V. Gool, "MHFormer: Multi-Hypothesis Transformer for 3D Human Pose Estimation," arXiv preprint arXiv:2111.12707, 2021.
- [5] S. Parab, A. Lamelas, A. Hassan, and P. Bhote, "Canoe Paddling Quality Assessment Using Smart Devices: Preliminary Machine Learning Study," arXiv.org, 2025.
- [6] S. Ren, K. He, R. Girshick, and J. Sun, "Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks," arXiv.org, Jun. 04, 2015.
- [7] A. Najlaoui et al., "AI-Driven Paddle Motion Detection," 2024 IEEE International Workshop on Sport, Technology and Research (STAR), pp. 290–295, Jul. 2024, doi: <https://doi.org/10.1109/star62027.2024.10635932>.
- [8] W. Zhu, X. Ma, Z. Liu, L. Liu, W. Wu, and Y. Wang, "MotionBERT: A Unified Perspective on Learning Human Motion Representations," arXiv preprint arXiv:2210.06551, 2022.
- [9] J. Zhang, Z. Tu, J. Yang, Y. Chen, and J. Yuan, "MixSTE: Seq2seq Mixed Spatio-Temporal Encoder for 3D Human Pose Estimation in Video," arXiv preprint arXiv:2203.00859, 2022.
- [10] L. Liu, S. Qiu, Z. Wang, J. Li, and J. Wang, "Canoeing Motion Tracking and Analysis via Multi-Sensors Fusion," Sensors, vol. 20, no. 7, p. 2110, Apr. 2020, doi: <https://doi.org/10.3390/s20072110>.
- [11] G. Hinton, O. Vinyals, and J. Dean, "Distilling the Knowledge in a Neural Network," 2015. Available: <https://arxiv.org/pdf/1503.02531>
- [12] I. Robinson, P. Robicheaux, M. Popov, D. Ramanan, and N. Peri, "RF-DETR: Neural Architecture Search for Real-Time Detection Transformers," *arXiv preprint*

arXiv:2511.09554, Nov. 2025.

[13]K. He, X. Chen, S. Xie, Y. Li, P. Dollár, and R. Girshick, “Masked Autoencoders Are Scalable Vision Learners,” Dec. 2021. Available: <https://arxiv.org/pdf/2111.06377>

[14]MMPose Contributors, “OpenMMLab Pose Estimation Toolbox and Benchmark,” GitHub, Aug. 01, 2020. <https://github.com/open-mmlab/mmpose>